

SAP - projekt

World happiness report

Tamara Ćorić, Ana Marić, Gregor Mihaljević, Petar Kuruc

2026-01-17

```
library(dplyr)
```

```
## Warning: package 'dplyr' was built under R version 4.3.3
```

```
##
```

```
## Attaching package: 'dplyr'
```

```
## The following objects are masked from 'package:stats':
```

```
##
```

```
## filter, lag
```

```
## The following objects are masked from 'package:base':
```

```
##
```

```
## intersect, setdiff, setequal, union
```

Uvod

Opis problema

World Happiness Report je publikacija Mreže rješenja za održivi razvoj Ujedinjenih naroda koja sadrži podatke o osjećaju sreće pojedinih nacija na skali od 0 do 10. Cilj je razumjeti kako čimbenici poput regije, BDP-a po stanovniku, životnog vijeka, socijalne podrške i slično utječu na iskazanu sreću te usporediti izvještaje iz 2023. i 2025. godine. Ova analiza omogućuje bolji uvid u područja koja uvelike doprinose osjećaju sreće stanovnika neke države kako bi se razumjele regionalne razlike i identificirali ključni prediktori kvalitete života u suvremenom društvu.

Deskriptivna analiza

Ručno smo spojili podatke u tablicama za 2023. i 2025. godinu radi bržeg uparivanja istih država sa različitim imenima u dvije tablice. 10 država se pojavljuje samo u podacima za 2025. godinu (Azerbajdžan, Belize, Eswatini, Kuwait, Lesotho, Libija, Oman, Somalia, Trinidad and Tobago, Yemen), pa su one ručno maknute iz skupa podataka.

```
whr_data = read.csv(file='WHR_2023_2025.csv')
```

Deskriptivna statistika:

```
summary(whr_data)
```

```
##      Country      Regional.indicator  Ladder.score  GDP.per.capita
## Length:137      Length:137      Min.   :1.859    Min.   : 251.3
## Class :character Class :character 1st Qu.:4.724    1st Qu.: 5382.5
## Mode  :character Mode  :character Median :5.684    Median : 14292.2
##                                     Mean  :5.540    Mean   : 22561.9
##                                     3rd Qu.:6.334    3rd Qu.: 37808.9
##                                     Max.   :7.804    Max.   :115838.2
##
## Social.support  Healthy.life.expectancy Freedom.to.make.life.choices
## Min.   :0.3413  Min.   :51.53    Min.   :0.3816
## 1st Qu.:0.7220  1st Qu.:60.65    1st Qu.:0.7239
## Median :0.8271  Median :65.84    Median :0.8005
## Mean   :0.7990  Mean   :64.97    Mean   :0.7874
## 3rd Qu.:0.8960  3rd Qu.:69.41    3rd Qu.:0.8745
## Max.   :0.9825  Max.   :77.28    Max.   :0.9614
##                                     NA's   :1
## Generosity      Perceptions.of.corruption
## Min.   : -0.254276  Min.   :0.1461
## 1st Qu.: -0.073543  1st Qu.:0.6678
## Median : 0.001419  Median :0.7736
## Mean   : 0.022444  Mean   :0.7254
## 3rd Qu.: 0.117025  3rd Qu.:0.8459
## Max.   : 0.531386  Max.   :0.9291
##
## Alcohol.consumption.Both.Sexes..L.year. Alcohol.consumption.Male..L.year.
## Min.   : 0.00      Min.   : 0.000
## 1st Qu.: 2.42      1st Qu.: 3.955
## Median : 6.04      Median : 9.370
## Mean   : 6.23      Mean   : 9.914
## 3rd Qu.:10.03     3rd Qu.:15.595
## Max.   :13.19     Max.   :21.610
## NA's   :6         NA's   :6
## Alcohol.consumption.Female..L.year. Crime.rate.Crime.Index
## Min.   :0.000      Min.   :15.23
## 1st Qu.:0.885      1st Qu.:33.42
## Median :2.530      Median :44.58
## Mean   :2.729      Mean   :44.07
## 3rd Qu.:4.465      3rd Qu.:53.42
## Max.   :6.340      Max.   :83.76
## NA's   :6         NA's   :24
## Healthcare.Legatum.Pro Prosperity.Index.Health.Score Gini.Coefficient...World.Bank
## Min.   :39.17      Min.   :24.60
## 1st Qu.:64.53      1st Qu.:32.50
## Median :72.23      Median :35.70
## Mean   :70.28      Mean   :37.47
## 3rd Qu.:77.88      3rd Qu.:42.05
## Max.   :86.89      Max.   :63.00
## NA's   :2         NA's   :10
## Happiness.score
## Min.   :1.364
## 1st Qu.:4.768
```

```
## Median :5.870
## Mean   :5.609
## 3rd Qu.:6.492
## Max.   :7.736
##
```

Vidimo da pojedine države (uključujući i one koje se pojavljuju samo u podacima za 2025. godinu) imaju nedostajuće podatke za pojedine značajke. To treba uzeti u obzir kod analize koja zahtijeva korištenje značajki koje nisu ocjena sreće.

1. Je li razina sreće u publikaciji za 2025. veća ili manja u usporedbi s istraživanjem provedenim godinu ranije?

Cilj ovog dijela analize je ispitati postoji li statistički značajna razlika u prosječnoj razini iskazane sreće država između World Happiness Reporta iz 2023. i 2025. godine. Budući da se radi o istim državama promatranima u dvije vremenske točke, primijenjen je upareni t-test.

Postavljamo sljedeće hipoteze:

H_0 : Ne postoji razlika u prosječnoj razini sreće država između 2023. i 2025. godine.

H_1 : Postoji razlika u prosječnoj razini sreće država između 2023. i 2025. godine.

Testiranje se provodi na razini značajnosti $\alpha = 0.05$.

Izvještaj za 2025. godinu sadrži isključivo podatke o razini sreće, dok izvještaj za 2023. godinu sadrži dodatne socioekonomske varijable. U ovom istraživačkom pitanju koriste se isključivo podatci o razini sreće.

```
whr_data = read.csv("WHR_2023_2025.csv", sep = ",")

happiness <- whr_data[, c("Country", "Ladder.score", "Happiness.score")]
colnames(happiness) <- c("country", "happiness_2023", "happiness_2025")

happiness <- na.omit(happiness)
```

U analizu su uključene samo države za koje su dostupni podatci o razini sreće u obje promatrane godine, čime se osigurava ispravno uparivanje opažanja.

```
summary(happiness$happiness_2023)
```


```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  1.859   4.724   5.684   5.540   6.334   7.804
```

```
summary(happiness$happiness_2025)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  1.364   4.768   5.870   5.609   6.492   7.736
```

Deskriptivne mjere pokazuju da je prosječna razina iskazane sreće u 2025. godini neznatno viša nego u 2023. godini. Medijan i kvartili također upućuju na blagi pomak distribucije prema višim vrijednostima.

```
boxplot(happiness$happiness_2023,
        happiness$happiness_2025,
        names = c("2023", "2025"),
        main = "Distribucija razine sreće po godinama",
        ylab = "Razina sreće")
```




Distribucije razine sreće u obje godine imaju sličan raspon i oblik. Prisutni su pojedinačni izdvojeni podatci, no bez izraženih asimetrija ili ekstremnih odstupanja. Iz deskriptivne analize nije moguće zaključiti postoji li statistički značajna razlika, zbog čega se provodi inferencijalna analiza.

```
diff <- happiness$happiness_2025 - happiness$happiness_2023
```


```
hist(diff,
      main = "Histogram razlika razine sreće (2025 - 2023)",
      xlab = "Razlika razine sreće")
```

Histogram razlika razine sreće (2025 – 2023)



```
qqnorm(diff, main = "Q-Q dijagram razlika razine sreće")  
qqline(diff, col = "steelblue", lwd = 2)
```

Q-Q dijagram razlika razine sreće



Normalnost razlika procijenjena je vizualno pomoću histograma i Q-Q dijagrama. Kako većina opažanja prati teorijsku normalnu razdiobu bez izraženih odstupanja, pretpostavka normalnosti smatra se zadovoljenom. Upareni t-test je robustan na manja odstupanja od normalnosti kod većeg broja opažanja.

S obzirom na uparenu strukturu podataka i zadovoljene pretpostavke, provodimo upareni t-test.

```
t.test(happiness$happiness_2025,
       happiness$happiness_2023,
       paired = TRUE,
       alternative = "two.sided")

##
## Paired t-test
##
## data: happiness$happiness_2025 and happiness$happiness_2023
## t = 3.332, df = 136, p-value = 0.001111
## alternative hypothesis: true mean difference is not equal to 0
## 95 percent confidence interval:
##  0.02809413 0.11013214
## sample estimates:
## mean difference
##      0.06911314
```

Dobivena p-vrijednost manja je od razine značajnosti $\alpha = 0.05$ pa odbacujemo nul-hipotezu i zaključujemo da postoji statistički značajna razlika u prosječnoj razini iskazane sreće država između 2023. i 2025. godine.

Iako je razlika statistički značajna, njezina apsolutna veličina je mala u odnosu na ljestvicu mjerenja. Promjena od približno 0.07 bodova na skali od 0 do 10 upućuje na to da se radi o suptilnoj promjeni u prosječnoj

razini sreće, koja nema izraženo praktično značenje na razini pojedinca.

2. Možemo li temeljem drugih dostupnih varijabli predvidjeti razinu sreće neke nacije? Koja je od njih najbolji prediktor razine sreće?

Za pitanje “Možemo li temeljem drugih dostupnih varijabli predvidjeti razinu sreće neke nacije?” koristit ćemo višestruku linearnu regresiju.

Za model odabiremo samo numeričke varijable koje ćemo koristiti u regresijama, a umjesto izbacivanja NA vrijednosti, što bi smanjilo veličinu skupa podataka i moglo uvesti pristranost, zamjenjujemo ih s medijanima.

```
whr_data2 <- read.csv("WHR_2023.csv")

colnames(whr_data2) <- c("Country", "Region", "LadderScore", "GDP_per_capita",
  "Social_support", "Healthy_life_expectancy",
  "Freedom_choices", "Generosity", "Corruption_perception",
  "Alcohol_consumption", "Crime_index", "Healthcare_index",
  "Gini_coefficient")

summary(whr_data2)
```

##	Country	Region	LadderScore	GDP_per_capita
##	Length:137	Length:137	Min. :1.859	Min. : 251.3
##	Class :character	Class :character	1st Qu.:4.724	1st Qu.: 5382.5
##	Mode :character	Mode :character	Median :5.684	Median : 14292.2
##			Mean :5.540	Mean : 22561.9
##			3rd Qu.:6.334	3rd Qu.: 37808.9
##			Max. :7.804	Max. :115838.2
##				
##	Social_support	Healthy_life_expectancy	Freedom_choices	Generosity
##	Min. :0.3413	Min. :51.53	Min. :0.3816	Min. : -0.254276
##	1st Qu.:0.7220	1st Qu.:60.65	1st Qu.:0.7239	1st Qu.: -0.073543
##	Median :0.8271	Median :65.84	Median :0.8005	Median : 0.001419
##	Mean :0.7990	Mean :64.97	Mean :0.7874	Mean : 0.022444
##	3rd Qu.:0.8960	3rd Qu.:69.41	3rd Qu.:0.8745	3rd Qu.: 0.117025
##	Max. :0.9825	Max. :77.28	Max. :0.9614	Max. : 0.531386
##		NA's :1		
##	Corruption_perception	Alcohol_consumption	Crime_index	Healthcare_index
##	Min. :0.1461	Min. : 0.00	Min. : 0.000	Min. :0.000
##	1st Qu.:0.6678	1st Qu.: 2.42	1st Qu.: 3.955	1st Qu.:0.885
##	Median :0.7736	Median : 6.04	Median : 9.370	Median :2.530
##	Mean :0.7254	Mean : 6.23	Mean : 9.914	Mean :2.729
##	3rd Qu.:0.8459	3rd Qu.:10.03	3rd Qu.:15.595	3rd Qu.:4.465
##	Max. :0.9291	Max. :13.19	Max. :21.610	Max. :6.340
##		NA's :6	NA's :6	NA's :6
##	Gini_coefficient	NA	NA	
##	Min. :15.23	Min. :39.17	Min. :24.60	
##	1st Qu.:33.42	1st Qu.:64.53	1st Qu.:32.50	
##	Median :44.58	Median :72.23	Median :35.70	
##	Mean :44.07	Mean :70.28	Mean :37.47	
##	3rd Qu.:53.42	3rd Qu.:77.88	3rd Qu.:42.05	
##	Max. :83.76	Max. :86.89	Max. :63.00	
##	NA's :24	NA's :2	NA's :10	

```

numeric_vars <- whr_data2 %>%
  select(LadderScore, GDP_per_capita, Social_support, Healthy_life_expectancy,
         Freedom_choices, Generosity, Corruption_perception,
         Crime_index, Healthcare_index, Gini_coefficient)

# medijani umjesto NA
model_data <- numeric_vars %>%
  mutate(across(
    .cols = everything(),
    .fns = ~ ifelse(is.na(.), median(., na.rm = TRUE), .)
  ))

```

Radimo Spearmanovu korelacijsku matricu. Spearman koristi rangove i stoga je otporniji na outliere i ne pretpostavlja linearnost u originalnim vrijednostima koje nisu skalirane.


```

cor_matrix <- cor(model_data, method = "spearman")

corrplot(cor_matrix,
  method = "color",
  type = "upper",
  order = "hclust",
  addCoef.col = "black",
  tl.col = "black",
  tl.srt = 45,
  title = "Matrica korelacije varijabli sreće",
  mar = c(0,0,1,0),
  number.cex = 0.7)

```

Matrica korelacije varijabli sreće



Iz matrice je vidljivo da GDP_per_capita i Social_support imaju najsnažnije pozitivne korelacije sa srećom, dok Corruption_perception i Gini_coefficient imaju najveću negativnu korelaciju.

Radimo model višestruke linearne regresije, uključujemo sve dostupne numeričke varijable kako bismo vidjeli njihov zajednički utjecaj na varijablu LadderScore. Cilj nam je dobiti koeficijent determinacije (R^2) koji će nam reći koliki postotak varijance sreće možemo objasniti ovim modelom. Također radimo i VIF za svaku varijablu kako bi provjerili multikolinearnost.

```
fit_full <- lm(LadderScore ~ GDP_per_capita + Social_support +
  Healthy_life_expectancy + Freedom_choices + Generosity +
  Corruption_perception + Crime_index + Healthcare_index +
  Gini_coefficient, data = model_data)
```

```
summary(fit_full)
```

```
##
## Call:
## lm(formula = LadderScore ~ GDP_per_capita + Social_support +
##     Healthy_life_expectancy + Freedom_choices + Generosity +
##     Corruption_perception + Crime_index + Healthcare_index +
##     Gini_coefficient, data = model_data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.28182 -0.18999  0.03541  0.27968  0.97197
##
```

```
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   -9.559e-01  7.721e-01  -1.238  0.217989
## GDP_per_capita  7.437e-06  3.511e-06   2.118  0.036103 *
## Social_support  3.909e+00  5.408e-01   7.228  4.05e-11 ***
## Healthy_life_expectancy 1.990e-02  1.237e-02   1.609  0.110174
## Freedom_choices 2.637e+00  4.485e-01   5.879  3.42e-08 ***
## Generosity      6.809e-02  3.004e-01   0.227  0.821071
## Corruption_perception -2.391e-01  3.203e-01  -0.746  0.456819
## Crime_index     -1.428e-01  3.858e-02  -3.701  0.000319 ***
## Healthcare_index  5.138e-01  1.356e-01   3.789  0.000232 ***
## Gini_coefficient  4.934e-04  3.655e-03   0.135  0.892848
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4624 on 127 degrees of freedom
## Multiple R-squared:  0.8464, Adjusted R-squared:  0.8355
## F-statistic: 77.74 on 9 and 127 DF,  p-value: < 2.2e-16
```

```
library(car)
vif(fit_full)
```

```
##              GDP_per_capita      Social_support Healthy_life_expectancy
##              3.911697              3.105158              3.195072
##      Freedom_choices      Generosity      Corruption_perception
##              1.615433              1.153168              2.043915
##      Crime_index      Healthcare_index      Gini_coefficient
##              38.069211              43.378322              1.432757
```

Rezultati punog modela pokazuje koeficijent determinacije Adjusted R-squared = 0.8355, što je dobar rezultat, ali za Healthcare_index i Crime_index dobivamo jako veliku multikolinearnost s ostalim varijablama (Variance Inflation Factor >40), što nam govori da model ne mora biti pouzdan.

$$VIF_j = \frac{1}{1 - R_j^2}$$

gdje je R_j^2 koeficijent determinacije dobiven regresijom varijable X_j na sve ostale nezavisne varijable u modelu.

Za drugi model izbacujemo varijablu Crime_index kako bismo probali smanjiti ostale VIF-ove.

```
fit_reduced <- lm(LadderScore ~ GDP_per_capita + Social_support +
  Healthy_life_expectancy + Freedom_choices + Generosity +
  Corruption_perception + Healthcare_index +
  Gini_coefficient, data = model_data)

summary(fit_reduced)
```

```
##
## Call:
## lm(formula = LadderScore ~ GDP_per_capita + Social_support +
##     Healthy_life_expectancy + Freedom_choices + Generosity +
##     Corruption_perception + Healthcare_index + Gini_coefficient,
```

```
##      data = model_data)
##
## Residuals:
##      Min        1Q      Median        3Q        Max
## -1.42361 -0.21098  0.03626  0.29688  1.06012
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    -1.405e+00  7.994e-01  -1.757  0.08132 .
## GDP_per_capita    1.034e-05  3.588e-06   2.880  0.00466 **
## Social_support    3.890e+00  5.669e-01   6.861 2.63e-10 ***
## Healthy_life_expectancy 2.727e-02  1.280e-02   2.131  0.03500 *
## Freedom_choices    2.551e+00  4.696e-01   5.433 2.69e-07 ***
## Generosity        -6.341e-03  3.143e-01  -0.020  0.98393
## Corruption_perception -4.137e-01  3.321e-01  -1.246  0.21519
## Healthcare_index    2.239e-02  2.876e-02   0.778  0.43777
## Gini_coefficient    1.392e-03  3.824e-03   0.364  0.71649
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4847 on 128 degrees of freedom
## Multiple R-squared:  0.8298, Adjusted R-squared:  0.8192
## F-statistic: 78.01 on 8 and 128 DF,  p-value: < 2.2e-16
```

```
library(car)
vif(fit_reduced)
```


```
##      GDP_per_capita      Social_support Healthy_life_expectancy
##      3.717034           3.104874           3.112117
##      Freedom_choices      Generosity      Corruption_perception
##      1.611139           1.148001           1.999545
##      Healthcare_index      Gini_coefficient
##      1.776133           1.426438
```

Vidimo da su sad sve VIF vrijednosti manje od 4 te nam to govori da je ovaj model puno pouzdaniji i dobivamo Adjusted R-squared = 0.8192.

Nastavljamo raditi grafove na temelju drugog modela.

```
model_data$predicted <- predict(fit_reduced)
model_data$residuals <- residuals(fit_reduced)
sigma_val <- summary(fit_reduced)$sigma


ggplot(model_data, aes(x = predicted, y = LadderScore)) +
  geom_point(aes(color = abs(residuals) > sigma_val), alpha = 0.6, size = 2) +
  scale_color_manual(values = c("darkgreen", "red"),
    labels = c("Unutar 1 SD", "Odstupanje (>1 SD)")) +
  geom_abline(intercept = 0, slope = 1, color = "blue", linetype = "dashed", size = 1) +
  labs(title = "Kvaliteta predviđanja: Stvarno vs. Predviđeno",
    x = "Predviđena razina sreće",
    y = "Stvarna razina sreće",
    color = "Odstupanje") +
  theme_minimal()
```



Na gornjem grafu vidimo za predikcije i kolika je greška u odnosu na prave vrijednosti. Kvalitetu modela provjeravamo analizom reziduala.

```
ggplot(model_data, aes(x = predicted, y = residuals)) +
  geom_hline(yintercept = 0, color = "black", size = 1) +
  geom_point(color = "steelblue", alpha = 0.5) +
  geom_smooth(method = "loess", color = "red", se = FALSE) +
  labs(title = "Analiza reziduala",
       x = "Predviđene vrijednosti",
       y = "Reziduali (Greška)") +
  theme_light()
```

Analiza reziduala




Vidimo da se reziduali nalaze oko 0 što nam govori da je model dobar.

Da izračunamo koja varijabla najviše utječe na razinu sreće uspoređujemo Bete, radimo posebno za model koji nije skaliran sa svim numeričkim varijablama te za model u kojem smo skalirali sve vrijednosti i izbacili `Crime_index` zbog multikolinearnosti.

```
coef_df <- as.data.frame(summary(fit_full)$coefficients[-1, ])  
coef_df$Variable <- rownames(coef_df)  
  
ggplot(coef_df, aes(x = reorder(Variable, Estimate), y = Estimate)) +  
  geom_bar(stat = "identity", fill = "orange", color = "darkorange") +  
  coord_flip() +  
  labs(title = "Utjecaj varijabli na ocjenu sreće (1. model)",  
        x = "Varijabla",  
        y = "koeficijent Beta") +  
  theme_minimal()
```

Utjecaj varijabli na ocjenu sreće (1. model)



```
model_data_scaled <- as.data.frame(scale(model_data %>% select(-predicted, -residuals)))
```

```
fit_scaled <- lm(LadderScore ~ GDP_per_capita + Social_support +
  Healthy_life_expectancy + Freedom_choices + Generosity +
  Corruption_perception + Crime_index + Healthcare_index +
  Gini_coefficient, data = model_data_scaled)
```

```
summary(fit_scaled)
```

```
##
## Call:
## lm(formula = LadderScore ~ GDP_per_capita + Social_support +
##     Healthy_life_expectancy + Freedom_choices + Generosity +
##     Corruption_perception + Crime_index + Healthcare_index +
##     Gini_coefficient, data = model_data_scaled)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.12450 -0.16667  0.03107  0.24535  0.85268
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  2.823e-16   3.465e-02   0.000 1.000000
## GDP_per_capita  1.457e-01   6.879e-02   2.118 0.036103 *
```

```
## Social_support      4.430e-01  6.129e-02   7.228 4.05e-11 ***
## Healthy_life_expectancy 1.000e-01  6.217e-02   1.609 0.110174
## Freedom_choices     2.599e-01  4.421e-02   5.879 3.42e-08 ***
## Generosity          8.465e-03  3.735e-02   0.227 0.821071
## Corruption_perception -3.711e-02  4.972e-02  -0.746 0.456819
## Crime_index         -7.942e-01  2.146e-01  -3.701 0.000319 ***
## Healthcare_index     8.681e-01  2.291e-01   3.789 0.000232 ***
## Gini_coefficient     5.619e-03  4.163e-02   0.135 0.892848
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4056 on 127 degrees of freedom
## Multiple R-squared:  0.8464, Adjusted R-squared:  0.8355
## F-statistic: 77.74 on 9 and 127 DF,  p-value: < 2.2e-16
```


```
# Skaliranje
```

```
model_data_scaled <- as.data.frame(scale(model_data %>% select(-predicted, -residuals)))
```

```
fit_scaled_reduced <- lm(LadderScore ~ GDP_per_capita + Social_support +
  Healthy_life_expectancy + Freedom_choices + Generosity +
  Corruption_perception + Healthcare_index +
  Gini_coefficient, data = model_data_scaled)
```

```
coef_scaled_reduced <- as.data.frame(summary(fit_scaled_reduced)$coefficients[-1, ])
coef_scaled_reduced$Variable <- rownames(coef_scaled_reduced)
```

```
ggplot(coef_scaled_reduced, aes(x = reorder(Variable, Estimate), y = Estimate)) +
  geom_bar(stat = "identity", fill = "orange", color = "darkorange") +
  coord_flip() +
  labs(title = "Utjecaj varijabli na ocjenu sreće (2. model)",
    x = "Varijabla",
    y = "koeficijent Beta") +
  theme_minimal()
```



Vidimo velike razlike između Beta koeficijenata u 1. i 2. grafu, no radi toga što je 2. model skaliran i nema veliku multikolinearnost, njegove rezultate smatramo relevantnijima, vidimo da su najveći faktori koji utječu na sreću Social support, Freedom choices i GDP, a najveći negativni utjecaj ima Corruption perception.

3. Postoje li razlike u iskazanoj sreći među različitim regijama?

Prvo ćemo postaviti hipoteze:

$$H_0 : \mu_1 = \mu_2 = \mu_3 = \mu_4 = \mu_5$$

$$H_1 : \mu_i \neq \mu_j \quad \text{za barem jedan par } (i, j)$$

Odlučili smo koristiti samo podatke iz 2025.

```
whr_3=whr_data[, c("Country", "Regional.indicator", "Happiness.score")]
```

Obzirom imamo velik broj regija od kojih neke imaju mali broj uzoaraka spojiti ćemo ih kako bismo mogli ispitati podatke jednofaktorskom ANOVA-om.

```
whr_3$grouped.region[whr_3$Regional.indicator == "East Asia" |
  whr_3$Regional.indicator == "Southeast Asia" |
  whr_3$Regional.indicator == "South Asia"] = "Asia"

whr_3$grouped.region[whr_3$Regional.indicator == "Latin America and Caribbean" |
  whr_3$Regional.indicator == "North America and ANZ"] = "Americas and ANZ"

whr_3$grouped.region[whr_3$Regional.indicator == "Central and Eastern Europe" |
```

```

whr_3$Regional.indicator == "Western Europe"] = "Europe"

whr_3$grouped.region[whr_3$Regional.indicator == "Commonwealth of Independent States" |
whr_3$Regional.indicator == "Middle East and North Africa"] = "ME, NA and CIS"

whr_3$grouped.region[whr_3$Regional.indicator == "Sub-Saharan Africa"] = "Sub-Saharan Africa"


```

Prije pokretanja ANOVA-e ćemo vizualizirati podatke.

```

ggplot(whr_3, aes(x = grouped.region, y = Happiness.score, fill = grouped.region)) +
  geom_boxplot(alpha = 0.7) +
  geom_point(position = position_jitter(width = 0.2), alpha = 0.5) +
  labs(title = "Razina sreće po grupiranoj regiji",
       x = "Grupa regija",
       y = "Razina sreće") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))

```



Jedna od pretpostavki za testiranje ANOVA-om jest normalnost reziduala, pa trebamo i to provjeriti, no prije konvertiramo grupirane regije.

```

whr_3$grouped.region <- as.factor(whr_3$grouped.region)
print(whr_3$grouped.region)

```

```
##      [1] Europe      Europe      Europe
```

```
## [4] Europe Europe Europe
## [7] Europe Europe Europe
## [10] Europe Europe Europe
## [13] Europe Europe Europe
## [16] Europe Europe ME, NA and CIS
## [19] ME, NA and CIS ME, NA and CIS ME, NA and CIS
## [22] ME, NA and CIS ME, NA and CIS ME, NA and CIS
## [25] ME, NA and CIS ME, NA and CIS Asia
## [28] Asia Asia Asia
## [31] Asia Asia Americas and ANZ
## [34] Americas and ANZ Americas and ANZ Americas and ANZ
## [37] Americas and ANZ Americas and ANZ Americas and ANZ
## [40] Americas and ANZ Americas and ANZ Americas and ANZ
## [43] Americas and ANZ Americas and ANZ Americas and ANZ
## [46] Americas and ANZ Americas and ANZ Americas and ANZ
## [49] Americas and ANZ Americas and ANZ Americas and ANZ
## [52] ME, NA and CIS ME, NA and CIS ME, NA and CIS
## [55] ME, NA and CIS ME, NA and CIS ME, NA and CIS
## [58] ME, NA and CIS ME, NA and CIS ME, NA and CIS
## [61] ME, NA and CIS ME, NA and CIS ME, NA and CIS
## [64] ME, NA and CIS ME, NA and CIS Americas and ANZ
## [67] Americas and ANZ Americas and ANZ Americas and ANZ
## [70] Asia Asia Asia
## [73] Asia Asia Asia
## [76] Asia Asia Asia
## [79] Asia Asia Asia
## [82] Asia Asia Asia
## [85] Sub-Saharan Africa Sub-Saharan Africa Sub-Saharan Africa
## [88] Sub-Saharan Africa Sub-Saharan Africa Sub-Saharan Africa
## [91] Sub-Saharan Africa Sub-Saharan Africa Sub-Saharan Africa
## [94] Sub-Saharan Africa Sub-Saharan Africa Sub-Saharan Africa
## [97] Sub-Saharan Africa Sub-Saharan Africa Sub-Saharan Africa
## [100] Sub-Saharan Africa Sub-Saharan Africa Sub-Saharan Africa
## [103] Sub-Saharan Africa Sub-Saharan Africa Sub-Saharan Africa
## [106] Sub-Saharan Africa Sub-Saharan Africa Sub-Saharan Africa
## [109] Sub-Saharan Africa Sub-Saharan Africa Sub-Saharan Africa
## [112] Sub-Saharan Africa Sub-Saharan Africa Sub-Saharan Africa
## [115] Sub-Saharan Africa Sub-Saharan Africa Sub-Saharan Africa
## [118] Europe Europe Europe
## [121] Europe Europe Europe
## [124] Europe Europe Europe
## [127] Europe Europe Europe
## [130] Europe Europe Europe
## [133] Europe Europe Europe
## [136] Europe Europe
## Levels: Americas and ANZ Asia Europe ME, NA and CIS Sub-Saharan Africa
```

```
library(car)
model <- aov(Happiness.score ~ grouped.region, data = whr_3)
shapiro_whr3 <- shapiro.test(residuals(model))
cat("Test normalnosti: p = ", shapiro_whr3$p.value, "\n")
```

```
## Test normalnosti: p = 8.011935e-05
```

Dobivamo jako malu p-vrijednost što znači da uzorci zadovoljavaju uvjet normalnosti reziduala.

```
anova_result <- aov(Happiness.score ~ grouped.region, data = whr_3)
summary(anova_result)
```

```
##                Df Sum Sq Mean Sq F value Pr(>F)
## grouped.region    4  98.28   24.57   39.61 <2e-16 ***
## Residuals       132  81.88    0.62
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Iz ovako male p-vrijednosti odbacujemo nul hipotezu i zaključujemo da postoje statistički značajne razlike u razinama sreće između regionalnih grupa, odnosno da barem jedna grupa ima drukciju srednju vrijednost razine sreće od ostalih.

4. Je li promjena razine sreće (poboljšanje/pogoršanje) između 2023. i 2025. godine nezavisna od regionalne pripadnosti zemalja?

```
whr_4=whr_data[, c("Country", "Regional.indicator", "Ladder.score", "Happiness.score")]
sum(!complete.cases(whr_4))
```

```
## [1] 0
```

Vidimo da nemamo nedostajućih vrijednosti u podacima koji su nam potrebni, pa nastavljamo s analizom.

Računamo promjenu sreće (2025-2023) i kategoriziramo ju kao poboljšanje ili pogoršanje

```
whr_4$Happiness.change=whr_4$Happiness.score-whr_4$Ladder.score
whr_4$Change.category=ifelse(whr_4$Happiness.change>0, "Poboljsanje", "Pogorsanje")
head(whr_4)
```

```
##                Country      Regional.indicator Ladder.score
## 1      Albania Central and Eastern Europe      5.2773
## 2 Bosnia and Herzegovina Central and Eastern Europe      5.6325
## 3      Bulgaria Central and Eastern Europe      5.4661
## 4      Croatia Central and Eastern Europe      6.1250
## 5      Czechia Central and Eastern Europe      6.8452
## 6      Estonia Central and Eastern Europe      6.4552
## Happiness.score Happiness.change Change.category
## 1      5.411      0.13370012      Poboljsanje
## 2      6.136      0.50349983      Poboljsanje
## 3      5.554      0.08789978      Poboljsanje
## 4      5.870     -0.25500000      Pogorsanje
## 5      6.775     -0.07020006      Pogorsanje
## 6      6.417     -0.03820019      Pogorsanje
```

```
contingency_table = table(whr_4$Regional.indicator, whr_4$Change.category)
added_margins_table=addmargins(contingency_table)
print(added_margins_table)
```

```
##
##                                Poboljsanje Pogorsanje Sum
## Central and Eastern Europe          10          7  17
## Commonwealth of Independent States    7          2   9
## East Asia                          5          1   6
## Latin America and Caribbean         18          1  19
## Middle East and North Africa         9          5  14
## North America and ANZ                0          4   4
## South Asia                          2          4   6
## Southeast Asia                      5          4   9
## Sub-Saharan Africa                  18         15  33
## Western Europe                      5         15  20
## Sum                                79         58 137
```

Pretpostavka testa je da očekivana frekvencija pojedinog razreda mora biti veća ili jednaka 5 (`chisq.test()` pretpostavlja da je ovaj uvjet zadovoljen stoga je prije provođenja testa potrebno to provjeriti).

```
for (col_names in colnames(added_margins_table)){
  for (row_names in rownames(added_margins_table)){
    if (!(row_names == 'Sum' | col_names == 'Sum')) {
      cat('Očekivane frekvencije za razred ', col_names, '-', row_names, ': ', (added_margins_table[row_names, col_names]), '\n')
    }
  }
}
```

```
## Očekivane frekvencije za razred Poboljsanje - Central and Eastern Europe : 9.80292
## Očekivane frekvencije za razred Poboljsanje - Commonwealth of Independent States : 5.189781
## Očekivane frekvencije za razred Poboljsanje - East Asia : 3.459854
## Očekivane frekvencije za razred Poboljsanje - Latin America and Caribbean : 10.9562
## Očekivane frekvencije za razred Poboljsanje - Middle East and North Africa : 8.072993
## Očekivane frekvencije za razred Poboljsanje - North America and ANZ : 2.306569
## Očekivane frekvencije za razred Poboljsanje - South Asia : 3.459854
## Očekivane frekvencije za razred Poboljsanje - Southeast Asia : 5.189781
## Očekivane frekvencije za razred Poboljsanje - Sub-Saharan Africa : 19.0292
## Očekivane frekvencije za razred Poboljsanje - Western Europe : 11.53285
## Očekivane frekvencije za razred Pogorsanje - Central and Eastern Europe : 7.19708
## Očekivane frekvencije za razred Pogorsanje - Commonwealth of Independent States : 3.810219
## Očekivane frekvencije za razred Pogorsanje - East Asia : 2.540146
## Očekivane frekvencije za razred Pogorsanje - Latin America and Caribbean : 8.043796
## Očekivane frekvencije za razred Pogorsanje - Middle East and North Africa : 5.927007
## Očekivane frekvencije za razred Pogorsanje - North America and ANZ : 1.693431
## Očekivane frekvencije za razred Pogorsanje - South Asia : 2.540146
## Očekivane frekvencije za razred Pogorsanje - Southeast Asia : 3.810219
## Očekivane frekvencije za razred Pogorsanje - Sub-Saharan Africa : 13.9708
## Očekivane frekvencije za razred Pogorsanje - Western Europe : 8.467153
```

Vidimo da uvijet nije zadovoljen, pa ćemo spojiti regije.

```
whr_4$grouped.region[whr_4$Regional.indicator == "East Asia" |
                      whr_4$Regional.indicator == "Southeast Asia" |
                      whr_4$Regional.indicator == "South Asia"] = "Asia"

whr_4$grouped.region[whr_4$Regional.indicator == "Latin America and Caribbean" |
```

```

whr_4$Regional.indicator == "North America and ANZ"] = "Americas and ANZ"

whr_4$grouped.region[whr_4$Regional.indicator == "Central and Eastern Europe" |
whr_4$Regional.indicator == "Western Europe"] = "Europe"

whr_4$grouped.region[whr_4$Regional.indicator == "Commonwealth of Independent States" |
whr_4$Regional.indicator == "Middle East and North Africa"] = "ME, NA and CIS"

whr_4$grouped.region[whr_4$Regional.indicator == "Sub-Saharan Africa"] = "Sub-Saharan Africa"

contingency_table = table(whr_4$grouped.region, whr_4$Change.category)
added_margins_table=addmargins(contingency_table)
print(added_margins_table)

```

```

##
##               Poboljsanje Pogorsanje Sum
## Americas and ANZ             18         5 23
## Asia                        12         9 21
## Europe                      15        22 37
## ME, NA and CIS              16         7 23
## Sub-Saharan Africa          18        15 33
## Sum                        79        58 137

```

```

for (col_names in colnames(added_margins_table)){
  for (row_names in rownames(added_margins_table)){
    if (!(row_names == 'Sum' | col_names == 'Sum')){
      cat('Očekivane frekvencije za razred ', col_names, '-', row_names, ': ', (added_margins_table[row_names, col_names]), '\n')
    }
  }
}

```

```

## Očekivane frekvencije za razred Poboljsanje - Americas and ANZ : 13.26277
## Očekivane frekvencije za razred Poboljsanje - Asia : 12.10949
## Očekivane frekvencije za razred Poboljsanje - Europe : 21.33577
## Očekivane frekvencije za razred Poboljsanje - ME, NA and CIS : 13.26277
## Očekivane frekvencije za razred Poboljsanje - Sub-Saharan Africa : 19.0292
## Očekivane frekvencije za razred Pogorsanje - Americas and ANZ : 9.737226
## Očekivane frekvencije za razred Pogorsanje - Asia : 8.890511
## Očekivane frekvencije za razred Pogorsanje - Europe : 15.66423
## Očekivane frekvencije za razred Pogorsanje - ME, NA and CIS : 9.737226
## Očekivane frekvencije za razred Pogorsanje - Sub-Saharan Africa : 13.9708

```

Sve očekivane frekvencije su veće od 5. Možemo nastaviti sa χ^2 testom.

```
chisq.test(contingency_table, correct=F)
```

```

##
## Pearson's Chi-squared test
##
## data: contingency_table
## X-squared = 9.909, df = 4, p-value = 0.04199

```

Na temelju Pearsonovog hi-kvadrat testa nezavisnosti, s p-vrijednošću od 0.042 ($p < 0.05$), odbacujemo nultu hipotezu na razini značajnosti od 5%. Postoji statistički značajna povezanost između regionalne pripadnosti i promjene sreće.